PIXLS: Preprint Information eXtraction for Life Sciences

Zwischenbericht

Prof. Dr. Philipp Schaer (Technische Hochschule Köln)
Prof. Dr. Konrad U. Förstner (ZB MED – Informationszentrum Lebenswissenschaften)
Benjamin Wolff (ZB MED – Informationszentrum Lebenswissenschaften)
Fabian Haak (Technische Hochschule Köln)

Berichtszeitraum: Januar 2023 – April 2025

Projektdaten

Projektname:	Preprint Information eXtraction for Life Sciences (PIXLS)
Förderkennzeichen:	492813820
Berichtszeitraum:	01. Januar 2023 – 30. April 2025
Tatsächlicher Projektstart:	01. Januar 2023
Vorauss. Projektende (ZB MED):	31. Dezember 2025
Vorauss. Projektende (TH Köln):	31. Oktober 2026 (kostenneutrale Verlängerung)
Antragsteller:	Prof. Dr. Philipp Schaer (TH Köln) Prof. Dr. Konrad U. Förstner (ZB MED)
Kontakt TH Köln:	philipp.schaer@th-koeln.de
Kontakt ZB MED:	foerstner@zbmed.de
Projekt-Webseite:	https://dfg-pixls.github.io/

Inhaltsverzeichnis

1 Einleitung und ursprüngliche Projektziele **2**

2 Neuausrichtung angesichts technologischer Umbrüche **2**

3 Projektfortschritt nach Arbeitspaketen (Jan. 2023 – Jun. 2025) **3**
3.1 AP 0: Projektmanagement, gemeinsame Infrastruktur, Dissemination 3
3.2 AP 1: Data Acquisition 4
3.3 AP 2: Information Extraction 5
3.4 AP 3: Knowledge Environment (ZB MED KE) 6
3.5 AP 4: LIVIVO 6
3.6 AP 5: Applied Research 7

4 Personelle Situation und Projektverlängerung **8**

5 Weitere Arbeitsplanung **8**

6 Publikationen und Öffentlichkeitsarbeit **9**

1 Einleitung und ursprüngliche Projektziele

Das PIXLS-Projekt (Preprint Information eXtraction for Life Sciences), das von der Deutschen Forschungsgemeinschaft (DFG) finanziert wird, zielt darauf ab, die wissenschaftlich bedeutsame, jedoch in bestehenden Informationssystemen häufig unzureichend erfasste Ressource der Preprint-Server methodisch zugänglich zu machen und der Forschungsgemeinschaft nutzbar zu machen. In den Lebenswissenschaften ermöglicht das rasche Publizieren von Preprints eine schnellere Verfügbarkeit neuer Forschungsergebnisse und fördert somit den wissenschaftlichen Diskurs, noch bevor das aufwendige Peer-Review-Verfahren abgeschlossen ist. Zudem trägt die offene und frühzeitige Veröffentlichung zur Beschleunigung von Kollaboration und Innovation in einem Bereich bei, der insbesondere bei dringlichen Fragestellungen – wie etwa in der medizinischen Forschung – von zeitnahen Erkenntnissen profitiert. Deshalb ist es von großer Bedeutung, diese Preprints über effiziente digitale Infrastrukturen und normierte Metadaten zugänglich und auffindbar zu machen. Wie im ursprünglichen Projektantrag dargelegt, bestand die Kernidee darin, zunächst eine Data Aquisition Pipeline aufzubauen (AP 1), die regelmäßig Preprints von verschiedenen lebenswissenschaftlichen Preprint-Plattformen sammelt, zu denen dann in einer Informations-Extraktionspipeline Metadaten und Volltexte extrahiert werden (AP 2). Diese Daten sollten im ZB MED Knowledge Environment (KE) homogenisiert, angereichert und integriert werden (AP 3). Darauf aufbauend war die Entwicklung von Mehrwertdiensten sowie deren Integration in das Discovery System LIVIVO von ZB MED geplant (AP 4). Ein weiterer Fokus lag auf der angewandten Forschung basierend auf den neu erschlossenen Daten (AP 5). Übergeordnetes Ziel war und ist es, die Informationsversorgung im deutschen Wissenschaftssystem zu stärken, aktuelle Forschungsergebnisse schneller zugänglich zu machen und die Nachnutzbarkeit der gewonnenen Daten gemäß den FAIR-Prinzipien (Findability, Accessibility, Interoperability, Reusability) zu gewährleisten.

2 Neuausrichtung angesichts technologischer Umbrüche

Seit der Konzeption und Bewilligung des PIXLS-Projekts hat sich die technologische Landschaft im Bereich der Künstlichen Intelligenz (KI), insbesondere der Verarbeitung natürlicher Sprache (Natural Language Processing, NLP) und des Information Retrieval (IR), fundamental und in rasantem Tempo gewandelt. Die Entwicklung und breite Verfügbarkeit hochleistungsfähiger großer Sprachmodelle (Large Language Models, im Folgenden LLMs) hat die Möglichkeiten zur Extraktion, Analyse und Synthese von Informationen aus textuellen und zunehmend auch multimodalen Datenquellen maßgeblich verändert. Auch die Etablierung des Retrieval-Augmented Generation (RAG)-Paradigmas eröffnet neue Perspektiven im IR und der Bibliotheks- und Informationswissenschaft (LIS) und wird die Art, wie Nutzende Informationen suchen und finden, in den kommenden Jahren auf transformative Art prägen. Insbesondere in Kombination mit Preprints entstehen so potenzielle Synergieeffekte: RAG-gestützte Systeme können neueste Forschung gezielt erschließen, kontextualisieren, verdichten und nutzungsorientiert aufbereiten – ein entscheidender Mehrwert für Forschung, Wissenschaftskommunikation und evidenzbasierte Entscheidungsprozesse.

Diese Umbrüche machten eine kritische Überprüfung und strategische Anpassung der ursprünglichen Ziele und methodischen Ansätze von PIXLS unumgänglich. Um sicherzustellen, dass das Projekt nicht nur seine ursprünglichen Kernziele in zeitgemäßer Form erreicht, sondern auch Ergebnisse liefert, die an der Spitze der technologischen Entwicklung stehen und einen nachhaltigen Mehrwert für die wissenschaftliche Gemeinschaft bieten, wurden folgende Neuausrichtungen vorgenommen:

Neudefinition der Informationsextraktion (AP 2): Der im Antrag skizzierte Ansatz zur Informationsextraktion, der unter anderem auf spezifischen Werkzeugen wie Fonduer basierte,

wurde als nicht mehr ausreichend leistungsfähig und flexibel im Vergleich zu modernen, LLM-basierten Methoden bewertet. Anstatt sich auf die Extraktion vordefinierter Entitäten mit älteren Werkzeugen zu beschränken, ermöglicht der Einsatz fortschrittlicher Dokumentenanalyse-Pipelines (wie Docling) und maßgeschneiderter LLM-Anwendungen eine wesentlich tiefere, kontextsensitivere und modalitätsübergreifende Extraktion. Dies umfasst nicht nur Metadaten und Volltext, sondern insbesondere auch semi-strukturierte Elemente wie **Tabellen** und **Abbildungen**, **Beschriftungen (Captions)**, sowie deren semantische Verknüpfung innerhalb des Dokuments. Dieser Paradigmenwechsel führte zur Entwicklung eines Information Extraction Frameworks, das eine deutlich reichhaltigere Informationsbasis schafft als ursprünglich geplant und somit eine Kerninnovation des Projekts darstellt (vgl. Unterabschnitt 3.3).

Weiterentwicklung des Informationszugangs (AP 3 & 4): Die ursprüngliche Vision einer Integration von Preprints in LIVIVO, primär über eine klassische Volltextsuche, wurde im Lichte von RAG neu bewertet. RAG-Systeme, die relevante Informationen aus einem Korpus extrahieren und diese mittels LLMs zu einer kohärenten Antwort synthetisieren, repräsentieren den aktuellen State-of-the-Art für die Beantwortung spezifischer Informationsbedürfnisse. Dies passt konzeptionell gut zum Charakter von Preprints, deren Stärke gerade im schnellen Zugang zu spezifischen, aktuellen Forschungserkenntnissen liegt. Eine reine Volltextsuche erscheint hierfür limitiert. Technische Beschränkungen der bestehenden LIVIVO-Infrastruktur (siehe Unterabschnitt 3.5) verstärkten die Notwendigkeit, alternative Wege zu beschreiten.

Verschiebung des Fokus in der Angewandten Forschung (AP 5): Angesichts der Potenziale der neuen Technologien und der reichhaltigeren extrahierten Daten wurde der Fokus der angewandten Forschung von traditionellen szientometrischen Analysen (wie Zitations- oder Altmetric-Analysen, die zudem durch technische und rechtliche Hürden bei der Datenerhebung erschwert wurden) hin zur angewandten Forschung im Bereich moderner IR-Methoden verschoben. Die Untersuchung der Leistungsfähigkeit von RAG-Systemen unter Einbeziehung verschiedener Modalitäten (Text, Tabellen), die Entwicklung und Evaluation von Methoden zur Generierung synthetischer Relevanzdaten mittels LLMs und die Erstellung angereicherter Testkollektionen stellen hochaktuelle Forschungsfragen dar, deren Beantwortung einen direkten Beitrag zur Weiterentwicklung von IR-Systemen für wissenschaftliche Inhalte leistet.

Diese strategische Neuausrichtung, getrieben durch externe technologische Entwicklungen und interne technische Analysen, ermöglicht es PIXLS, die ursprünglichen Kernziele – die Erschließung und Nutzbarmachung von Preprints – auf einem wesentlich höheren technologischen Niveau und mit einem größeren potenziellen Nutzen für die Endnutzer zu verfolgen. Die folgenden Abschnitte dokumentieren den Projektfortschritt detailliert vor dem Hintergrund dieser notwendigen und zukunftsweisenden Anpassungen.

3 Projektfortschritt nach Arbeitspaketen (Jan. 2023 – Jun. 2025)

Im Berichtszeitraum wurden signifikante Fortschritte in allen zentralen Arbeitspaketen erzielt, wobei die in der Präambel (Abschnitt 2) beschriebenen technologischen Entwicklungen zu Anpassungen in der Umsetzung führten.

3.1 AP 0: Projektmanagement, gemeinsame Infrastruktur, Dissemination

Die Koordination zwischen den Projektpartnern TH Köln und ZB MED wurde durch regelmäßige virtuelle und physische Treffen sichergestellt. Die interne Kommunikation und das Aufgabenmanagement erfolgen über etablierte Kanäle. Eine zentrale technische Infrastruktur für die gemeinsame Softwareentwicklung und den Datenaustausch wurde erfolgreich implementiert und wird

aktiv genutzt. Hierzu zählen insbesondere Versionskontrollsysteme (GitLab) und Kommunikationsplattformen (Mattermost). Ein gemeinsamer technischer Workflow, der auf Containerisierung (Docker) und Git Workflow setzt, wurde etabliert. Dies fördert nicht nur die Transparenz und Effizienz der Zusammenarbeit, sondern legt auch eine wichtige Grundlage für die Nachnutzbarkeit und Reproduzierbarkeit der entwickelten Softwarekomponenten.

Die externen Disseminationsaktivitäten, wie die Organisation von Workshops für externe Forschende, die Produktion von Podcast-Beiträgen oder die Einrichtung einer dedizierten Projektwebseite mit Blog, wurden im Berichtszeitraum zunächst zurückgestellt. Diese Entscheidung ist primär den tiefgreifenden methodischen Anpassungen in den Kernarbeitspaketen (insbesondere AP 2 und AP 5) geschuldet. Es erschien sinnvoll, zunächst robuste und wissenschaftlich fundierte Ergebnisse zu erarbeiten, bevor diese breit kommuniziert werden. Auf der Projektwebsite `https://dfg-pixls.github.io/` wird jedoch über das Projekt und Forschungsergebnisse berichtet und zukünftig auch Ressourcen zur Verfügung gestellt. Mit der Konzeption und ersten Implementierung eines Information-Extraction-Frameworks sind zentrale Grundlagen für die Dissemination geschaffen. Ein Workshop im letzten Projektjahr sowie ein Abschlussworkshop sollen externen Forschenden die Nutzung der im Rahmen des PIXLS Projektes produzierten Artefakte und Systeme und konkrete Anwendungsszenarien aufzeigen und die Projektergebnisse gleichzeitig validieren.

3.2 AP 1: Data Acquisition

Ziel dieses Arbeitspakets ist der Aufbau einer Infrastruktur zur systematischen und kontinuierlichen Sammlung von Metadaten und Volltexten von Preprint-Servern. Hier wurden die ursprünglichen Ziele nicht nur erreicht, sondern deutlich übertroffen. Die ursprünglich angedachte intensive Nutzung des OAI-PMH-Protokolls erwies sich als weniger zielführend, da inzwischen viele relevante Plattformen aktuellere und umfassendere Daten über REST-APIs bereitstellen. Es wurde eine robuste Software-Infrastruktur entwickelt, die auf einem modularen Pipeline-Ansatz (Extract, Load, Transform - ELT) basiert. Diese Pipeline ermöglicht die tagesaktuelle Akquisition von Dokumenten von diversen Preprint-Servern.

Die ursprünglich geplante Zahl der Preprint-Server wurde deutlich ausgeweitet, vor allem durch die Einbindung zahlreicher Open Science Framework (OSF) basierter Plattformen. Damit erfasst das System einen weitaus größeren, repräsentativeren Anteil an Life-Science-Preprints. Die Preprints und Metadaten (Informationen zu Autoren, Zugehörigkeiten, Veröffentlichungsdaten, Kategorisierungen, Szientometrische Informationen, etc.) werden über robuste REST-APIs bezogen, um eine hohe Datenqualität und Aktualität zu gewährleisten und die Abhängigkeit von fragilen Web-Scraping-Verfahren zu minimieren. Ein eigens entwickeltes, asynchrones Python-Framework berücksichtigt plattformspezifische Rate-Limits und realisiert per Leaky-Bucket-Verfahren eine kontinuierliche, regelkonforme Akquise. Dank Nebenläufigkeit bleibt die Performance auch bei hohen Zugriffszahlen und paralleler Nutzung mehrerer APIs gewährleistet. Entsprechend dem ELT-Paradigma werden die Rohdaten zunächst in einer Staging Area gespeichert, die als Ausgangspunkt für nachgelagerte Transformationsprozesse dient. Zur Sicherstellung von Robustheit und Zuverlässigkeit wurde zudem eine umfassende Testsuite implementiert. Die gewonnenen Daten, insbesondere die PDF-Dokumente der Preprints, bilden die essenzielle Eingabe für die nachfolgende Informationsextraktion in AP 2. Aktuell umfasst der Preprintkorpus derzeit rund 530.000 Preprints (siehe Tabelle 1). Die entwickelte Akquise-Pipeline ist modular aufgebaut und soll perspektivisch als Open-Source-Komponente und als Service auf ZB MED Infrastruktur zur Nachnutzung durch Dritte bereitgestellt werden, was dem Open-Science-Gedanken des Projekts entspricht.

3.3 AP 2: Information Extraction

Dieses Arbeitspaket hat, wie eingangs dargelegt, die signifikanteste Transformation erfahren. Der ursprüngliche Plan, eine Extraktionspipeline basierend auf dem Werkzeug Fonduer zu implementieren, wurde zugunsten eines wesentlich leistungsfähigeren und flexibleren Ansatzes aufgegeben. Erste explorative Arbeiten in diesem Bereich nutzten einen auf dem dokumentenparsendem Werkzeug Papermage basierenden Workflow, der jedoch noch stark von externen, teils proprietären LLMs abhängig war. Daher wurde schließlich Docling als Kern des Parsings von Dokumenten eingeführt, mit dem sich eine von geschlossenen LLMs unabhängige Extraktionspipeline verwirklichen ließ.

Das zentrale Ergebnis dieses Arbeitspakets ist die Konzeption, Entwicklung und erfolgreiche wissenschaftliche Publikation des **REANIMATOR**-Frameworks und des zugrunde liegenden Datenmodells. Ein entsprechender Beitrag wird bei der international führenden Konferenz SIGIR 2025 publiziert. REANIMATOR ist ein Toolkit, das darauf ausgelegt ist, Dokumentenkorpora (insbesondere wissenschaftliche Publikationen im PDF-Format, wie die in AP 1 gesammelten Preprints) substantiell anzureichern und für moderne IR-Aufgaben, insbesondere RAG, aufzubereiten. Die Arbeit entstand in Kooperation mit dem JoIE Projekt, an dem die TH Köln und das Science Media Center beteiligt sind.

Die REANIMATOR-Pipeline umfasst im Kern folgende Schritte:

1. **Eingabe:** Verarbeitung von PDF-Dokumenten, typischerweise bereitgestellt durch AP 1.
2. **Dokumentenparsing (mittels Docling):** Tiefgreifende Analyse der PDF-Struktur zur Extraktion des Volltextes unter Berücksichtigung des Layouts sowie zur Identifikation und Extraktion multimodaler Elemente wie Tabellen und Abbildungen inklusive ihrer Beschriftungen (Captions). Der Ansatz ermöglicht hierbei eine Unabhängigkeit von proprietären Modellen und Flexibilität, somit ist auch die zukünftige Aktualisierbarkeit gewährleistet.
3. **Kontextualisierung:** Semantische Verknüpfung der extrahierten Elemente. Insbesondere werden Tabellen und Abbildungen mit ihren expliziten Erwähnungen im Volltext (In-Text References) verbunden. Dies reichert die isolierten Elemente um wichtigen Kontext an, der für die spätere Relevanzbewertung und das Retrieval entscheidend ist.
4. **Strukturierte Ausgabe:** Speicherung der extrahierten und verknüpften Informationen (Textsegmente, Tabellenstrukturen, Bildreferenzen, Metadaten, Kontextinformationen) in einer relationalen Datenbank, die eine flexible Abfrage und Weiterverarbeitung ermöglicht.
5. **Zusammenführung mit Metadaten:** Homogenisierung und Zusammenführung der extrahierten und verknüpften Informationen mit den Metadaten der in AP 1 bezogenen Informationen zu den Publikationen in der relationalen Datenbank.
6. **Synthetische Relevanzbewertung (optional):** Einsatz von LLMs zur automatisierten Generierung von Relevanzurteilen für extrahierte Informationseinheiten (z.B. Textpassagen, Tabellen) bezüglich definierter Informationsbedürfnisse (Topics), um Testkollektionen für Evaluationszwecke zu erstellen (siehe AP 5).

Die im Rahmen von REANIMATOR entwickelte Extraktionspipeline und das Datenmodell bilden die Grundlage für die gesammelten und extrahierten Daten sowie die Nutzbarmachung in innovativen Retrieval-Szenarien (AP 4/AP 4). Die Pipeline wird kontinuierlich weiterentwickelt.

Zusätzlich zum Extraction Framework wurde an der Evaluation von Lesbarkeit und Verständlichkeit von wissenschaftlichen Texten für Nicht-Experten sowie eines Text-Simplifizierungsansatzes gearbeitet. Eine solche Komponente kann, insbesondere in Verbindung mit einem RAG-Ansatz, die VVerständlichkeit von Preprint Inhalten für eine möglichst breite Zielgruppe ermöglichen.

3.4 AP 3: Knowledge Environment (ZB MED KE)

Die in AP 1 gewonnenen Metadaten sowie die strukturierten Metadaten zu den mittels REANIMATOR (AP 2) extrahierten Elementen (Dokumente, Tabellen, Abbildungen) werden für die Integration in das ZB MED Knowledge Environment (KE) aufbereitet. Ein Workflow zur Transformation der Daten in das LIVIVO-interne XML-Format wurde etabliert. Zu diesem Zweck wurde ein eigenes Python-Package entwickelt, das die deklarative Beschreibung komplexer Transformationen von Preprint-Datenquellen in ein strukturiertes Zielformat ermöglicht. Hierfür kommt eine eigens entwickelte domänenspezifische Sprache (Domain Specific Language, DSL) zum Einsatz, die eine flexible und vereinfachte Modellierung in YAML erlaubt. Anpassungen der Transformationslogik oder Erweiterungen auf zusätzliche Formate und Quellen lassen sich direkt über YAML-Dateien vornehmen, ohne Änderungen am Quellcode. Dieser Ansatz stellt sicher, dass künftig auch weitere Preprintquellen und andere Ausgabeformate mit minimalem Aufwand unterstützt werden können, bei maximaler Wiederverwendbarkeit der bestehenden Logik. Die Robustheit der Transformationen wird durch eine begleitende Testsuite gewährleistet. Im Staging-Bereich, realisiert durch eine Postgres-Datenbank, werden alle Versionen eines Preprints vorgehalten. Im aktuellen LIVIVO-Suchindex wird hingegen nur die jeweils neueste Version übernommen, um Redundanzen zu vermeiden. Die aufbereiteten Metadaten sollen über die bestehenden Schnittstellen von ZB MED KE, wie z.B. Z39.50, zugänglich gemacht werden, um eine Nachnutzung zu ermöglichen.

Zur Vorbereitung des Datensatzes für weiterführende Analyseaufgaben wie Textklassifikation und semantische Ähnlichkeitssuche wurden verschiedene Embedding-Methoden erprobt, um strukturelle und inhaltliche Muster in den Preprints zu identifizieren. Im Fokus standen semantische Anreicherungen und deren Potenzial, die Qualität der Embeddings für nachgelagerte Tasks zu verbessern. Ein messbarer Performancegewinn konnte erzielt und in einer Veröffentlichung dokumentiert werden, die im Rahmen der NSLP2024-Konferenz[1] angenommen, publiziert und in einer begleitenden Postersession präsentiert wurde. Die entwickelte Pipeline zur semantischen Anreicherung von Embeddings stellt eine potenzielle Erweiterung der ZB MED KE dar.

3.5 AP 4: LIVIVO

Das Ziel dieses Arbeitspakets, die Integration der Preprint-Daten in LIVIVO, wird in Bezug auf die Metadaten wie geplant verfolgt. Die Indexierung der Metadaten (siehe AP 3) ist in Vorbereitung. Anpassungen an der LIVIVO-Weboberfläche zur Kennzeichnung von Preprints und die Erweiterung des Alerting-Services sind ebenfalls geplant.

Die ursprünglich angedachte Implementierung einer direkten Volltextsuche innerhalb von LIVIVO ist jedoch, wie bereits in der Präambel und in AP 3 erläutert, aufgrund technischer Limitationen der bestehenden LIVIVO-Infrastruktur und der damit verbundenen Performance-Risiken nicht sinnvoll umsetzbar.

Um die Limitationen der LIVIVO-Infrastruktur gezielt zu umgehen, wurde ein prototypisches Retrievalsystem speziell für die Nutzung des gewonnenen Preprint-Datensatzes entwickelt. Die modulare Architektur von Backend und Frontend ermöglicht eine flexible und unkomplizierte Erprobung, unabhängig vom LIVIVO-Systembetrieb. Einzelne technische Komponenten, wie etwa der Suchindex, können problemlos durch alternative Technologien ersetzt werden, was gezielte technologische Experimente begünstigt. Die Preprints wurden in das experimentelle Retrievalsystem eingespielt und sind dort suchbar. Die Umsetzung einer Volltextsuche ist in diesem Kontext ebenfalls vorgesehen.

[1] https://nfdi4ds.github.io/nslp2024/

3.6 AP 5: Applied Research

Im Zuge der Neuausrichtung fokussierte sich die angewandte Forschung auf moderne Information-Retrieval-Methoden auf Basis des in AP 2 entwickelten REANIMATOR-Frameworks. Die wichtigsten Ergebnisse umfassen:

Evaluation synthetischer Relevanzurteile für Preprints: Ein zentrales Ergebnis ist die systematische Prüfung, wie geeignet LLMs sind, Relevanzurteile für aus wissenschaftlichen Dokumenten extrahierte Textpassagen und Tabellen zu erzeugen. Mit den Topics der TREC-COVID-Kollektion generierten verschiedene LLMs automatisiert vierstufige sowie binäre Labels, die per Cohen's Kappa mit Expertenannotation verglichen wurden. Laut REANIMATOR-Paper erreichen die Modelle eine mit menschlichen Urteilen vergleichbare Übereinstimmung und übertreffen einfache Heuristiken wie das Dokumentenlabel deutlich. REANIMATOR ist vollständig quelloffen verfügbar (`https://github.com/irgroup/Reanimator`).

Evaluation von multimodaler RAG für wissenschaftliche Inhalte: Basierend auf multimodalen Daten (Text, Tabellen, Kontext) wurde der Einfluss von Tabellen auf RAG-Systeme untersucht. Retrieval-Strategien (nur Text, nur Tabellen, kombiniert) wurden verglichen, und die LLM-Antworten per RAGAS sowie paarweisen Elo-Ratings bewertet. Das REANIMATOR-Paper zeigt, dass Tabellen die Antworten signifikant hilfreicher und informativer machen.

Erstellung einer angereicherten Testkollektion (TREC-COVID+): Als konkretes, nachnutzbares Ergebnis wurde die etablierte TREC-COVID Testkollektion erweitert und als TREC-COVID+ bereitgestellt. Diese angereicherte Kollektion ist eine wertvolle Benchmark-Ressource für künftiges biomedizinisches IR, insbesondere Table Retrieval und RAG, und die verwendeten Methoden lassen sich direkt auf Preprint-Korpora übertragen.

Bedeutung der Erkenntnisse für die Entwicklung einer Preprint-Such-Plattform: Wissenschaftliche Preprints, insbesondere in den Lebenswissenschaften, präsentieren wesentliche Ergebnisse, Daten und methodische Details häufig in Tabellen oder Abbildungen. Textbasierte Retrieval- und RAG-Verfahren erfassen diese Informationsanteile jedoch nur unzureichend. Die durchgeführten RAG-Experimente belegen empirisch, dass die Einbeziehung tabellarischer Daten präzisere, umfassendere und für Nutzer nutzbringendere Antworten liefert und somit den multimodalen Extraktionsansatz (AP 2) legitimiert. Die validierte Methode der synthetischen Relevanzgenerierung ermöglicht darüber hinaus eine skalierbare, schnelle und kosteneffiziente Erstellung hochwertiger Bewertungsdaten für nicht-textuelle Inhalte – eine zentrale Voraussetzung, um spezialisierte Retrieval-Systeme für Life-Science-Preprints zu entwickeln, zu evaluieren und den Zugriff auf relevante Inhalte über bloße Metadaten hinaus zu verbessern.

Text Simplification und Simplicity Evaluation: Im Projekt wurden Verfahren zur Textvereinfachung für nicht-fachliche Zielgruppen sowie adressatenspezifische Lesbarkeitsevaluation entwickelt. Die Resultate erschienen als Beiträge auf den ACL 2024 und EMNLP 2024 Konferenzen. Diese Ansätze fließen direkt in die adressatengerechte Informationssynthese der RAG-Komponente ein und ermöglichen es, aktuelle Forschungsergebnisse auch beispielsweise Journalist:innen, Schüler:innen und anderen fachfremden Interessierten verständlich zu präsentieren.

Entwicklung der MIRAGES Retrieval Plattform: Die im Rahmen der RAG-Evaluierungen identifizierte Bedarfslage führte zur Konzeption von MIRAGES (Multimodal Information, Retrieval Augmented Generation, Evaluation, & Simulation). MIRAGES wird derzeit als prototypische Plattform mit API und Weboberfläche entwickelt, die explizit für den multimodalen RAG-Zugriff auf die mittels REANIMATOR aufbereiteten Preprint-Daten ausgelegt ist und dabei eine

Vielzahl an Möglichkeiten zur Steuerung der Suche über die in AP 1 gesammelten Metadaten der Veröffentlichungen (Veröffentlichungsdatum, Zugriffszahlen, Tags, etc.) bietet. Ein zentrales Merkmal bildet die parametrische Gewichtung der Modalitäten (beispielsweise Textpassagen gegenüber Tabellen) im RAG-Prozess, sowohl über die Benutzeroberfläche als auch programmatisch via API. Diese API ermöglicht nicht nur die Integration in andere Systeme, sondern auch systematisches Aufzeichnen und Simulationen von Nutzerverhalten. MIRAGES dient somit als Live-System und Testumgebung in einer kontrollierten Umgebung, um die Vorzüge von RAG und multimodalem Retrieval im wissenschaftlichen Kontext erfahrbar zu machen und zu evaluieren. Dies erlaubt es, Performance-Charakteristika des Systems unter realitätsnahen Bedingungen zu analysieren und Nutzeranforderungen an ein solches System besser zu verstehen.

4 Personelle Situation und Projektverlängerung

Die personelle Besetzung des Projekts entspricht weitgehend der Planung. Auf Seiten der TH Köln ist Herr Fabian Haak als wissenschaftlicher Mitarbeiter im Projekt tätig. Aufgrund von Elternzeit und der Übernahme einer befristeten Elternzeitvertretung in Absprache mit allen beteiligten Projektpartnern ergaben sich Änderungen in der Projektlaufzeit auf Seiten der TH Köln. Herr Haak pausiert seine Tätigkeit im PIXLS-Projekt vollständig im Zeitraum vom 01. März 2025 bis zum 31. August 2025. Um die Projektziele auf Seiten der TH Köln dennoch vollumfänglich erreichen zu können, wurde bei der DFG eine kostenneutrale Verlängerung der Projektlaufzeit für den Teilantrag der TH Köln bis zum 31. Oktober 2026 beantragt. Diese Verlängerung wurde bewilligt. Während der mit allen Beteiligten abgesprochenen sechsmonatigen Pausierung werden keine DFG-Mittel für diese Personalstelle abgerufen. Die Projektarbeiten bei ZB MED sind von dieser Regelung unberührt und werden planmäßig bis zum ursprünglich vorgesehenen Projektende am 31. Dezember 2025 fortgeführt. Die Koordination der Projektaktivitäten wird während der verlängerten Laufzeit weiterhin eng zwischen den Partnern abgestimmt.

5 Weitere Arbeitsplanung

Für die verbleibende Projektlaufzeit (bis Ende 2025 für ZB MED, bis Oktober 2026 für TH Köln) sind die folgenden zentralen Arbeitsschritte geplant, um die Projektziele unter Berücksichtigung der erfolgten Anpassungen zu erreichen:

- **Finalisierung der Datenakquise und -extraktion (AP 1 & AP 2):** Die entwickelte Akquise-Pipeline (AP 1) wird kontinuierlich gewartet und bei Bedarf an Änderungen der Quellplattformen angepasst. Das REANIMATOR-Framework (AP 2) wird weiter stabilisiert und für einen robusteren Einsatz optimiert. Abbildungen, die für die SIGIR Publikation noch nicht Teil der Pipeline waren, werden ergänzt. Eine Veröffentlichung in Form einer NFDI Kooperation, in der Das Framework eine zentrale Verwendung findet, ist in Arbeit.
- **Integration und Bereitstellung der Metadaten (AP 3):** Die regelmäßige Integration der aufbereiteten Preprint-Metadaten in das ZB MED KE wird fortgesetzt. Die Bereitstellung dieser Metadaten über die KE-API wird finalisiert und dokumentiert, um die Nachnutzung durch Dritte zu ermöglichen.
- **Entwicklung und Evaluation von MIRAGES (AP 4 & AP 5):** Geplant sind die Entwicklung und Evaluationen der Plattform im Rahmen eines Workshops, z.B. hinsichtlich der Qualität der generierten Antworten im Vergleich von RAG zu einer reinen Metadatensuche.

- **Durchführung von Workshops (AP 0):** Die Planung und Durchführung von Workshops für externe Forschende in Q4 2025 und Abschließend Q2 2026 wird konkretisiert. Ziel ist, die Projektergebnisse vorzustellen und zu evaluieren.
- **Open Science und Dissemination (Alle APs):** Die relevanten Softwarekomponenten (insb. Teile der Akquise-Pipeline, REANIMATOR-Framework und MIRAGES Plattform) werden aufbereitet und unter einer geeigneten Open-Source-Lizenz (z.B. auf GitLab/GitHub) veröffentlicht. Die erzeugten Datensätze und Modelle werden, soweit lizenzrechtlich möglich, ebenfalls publiziert. Die wissenschaftlichen Ergebnisse werden weiterhin auf Konferenzen präsentiert und in Fachjournalen publiziert.
- **Abschlussbericht:** Rechtzeitige Erstellung des finalen Projektberichts für die DFG.

6 Publikationen und Öffentlichkeitsarbeit

Im Berichtszeitraum wurden Vorarbeiten geleistet und eine zentrale Publikation zur Veröffentlichung angenommen, die wesentliche Ergebnisse aus AP 2 und AP 5 zusammenfasst:

1. Engelmann, B., Haak, F., Schaer, P., Abdoust, M. E., Netze, L., & Bittkowski, M. (2025). *REANIMATOR: Reanimate Retrieval Test Collections with Extracted and Synthetic Resources*. SIGIR 2025 (The 48th International ACM SIGIR Conference on Research and Development in Information Retrieval). Preprint verfügbar: https://arxiv.org/abs/2504.07584.
2. Engelmann, B., Kreutz, C.K., Haak, F., Schaer, P. (2024). *ARTS: Assessing Readability & Text Simplicity*. In Findings of the Association for Computational Linguistics: EMNLP 2024 (pp. 14925–14942), Miami, Florida, USA: Association for Computational Linguistics. https://doi.org/10.18653/v1/2024.findings-emnlp.877.
3. Keller, J., Engelmann, B., Haak, F., Schaer, P., Kroll, H., & Kreutz, C. K. (2024). *CIR at TREC 2024 RAG: Task 2 - Augmented Generation with Diversified Segments and Knowledge Adaption*. In The Thirty-Third Text REtrieval Conference Proceedings (TREC 2024), Gaithersburg, MD, USA, November 15-18, 2024 (NIST SP 1329). National Institute of Standards and Technology. Available via: https://trec.nist.gov/pubs/trec33/papers/CIR.rag.pdf.
4. Kreutz, C., Haak, F., Engelmann, B., & Schaer, P. (2024). *BATS: BenchmArking Text Simplicity*. Findings of the Association for Computational Linguistics: ACL 2024, 11968–11989, Bangkok, Thailand. Association for Computational Linguistics. https://doi.org/10.18653/v1/2024.findings-acl.712.
5. Engelmann, B., Haak, F., Kreutz, C. K., Nikzad Khasmakhi, N., & Schaer, P. (2023). *Text Simplification of Scientific Texts for Non-Expert Readers*. Preprint verfügbar: https://arxiv.org/abs/2307.03569.
6. Wolff, B., Seidlmayer, E., & Förstner, K. U. (2024, May). *Enriched BERT embeddings for scholarly publication classification*. In International Workshop on Natural Scientific Language Processing and Research Knowledge Graphs (pp. 234-243). Cham: Springer Nature Switzerland. https://link.springer.com/chapter/10.1007/978-3-031-65794-8_16.

Prof. Dr. Konrad U. Förstner

Prof. Dr. Philipp Schaer
(Technische Hochschule Köln)

(ZB MED – Informationszentrum Lebenswissenschaften)

Preprint-Repository	**Anzahl**
biorxiv	276,106
osf	87,405
medrxiv	66,099
psyarxiv	49,766
socarxiv	19,202
inarxiv	15,995
thesiscommons	2,979
engrxiv	2,035
edarxiv	1,977
eartharxiv	1,649
lawarchive	1,294
ecoevorxiv	978
metaarxiv	758
africarxiv	535
marxiv	452
agrixiv	393
sportrxiv	378
lissa	317
ecsarxiv	307
mindrxiv	300
arabixiv	298
mediarxiv	283
paleorxiv	229
lawarxiv	169
bodoarxiv	161
biohackrxiv	138
frenxiv	128
indiarxiv	121
nutrixiv	88
focusarchive	76
coppreprints	26
newaddictionsx	3
Total	**530,645**

Tabelle 1: Anzahl der gesammelten Preprints pro Repository